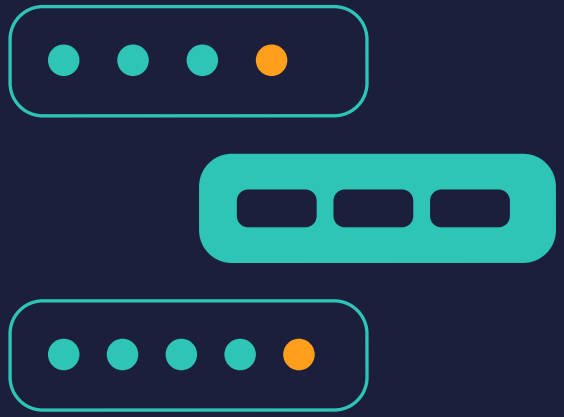
دوره مهندسی LLM و هوش مصنوعی مولد



جلسه ۱

شروع کار با مدل‌های زبانی بزرگ

پیش‌بینی توکن بعدی، دما، توکن‌سازی، Ollama و API سازگار با OpenAI

کیوان محمودی

در این جلسه

۱ LLM چیست؟ پیش‌بینی توکن بعدی

۲ دما و نمونه‌برداری

۳ توکن‌سازی و زبان فارسی

۴ سه مرحله ساخت یک دستیار

۵ اجرای مدل با Ollama

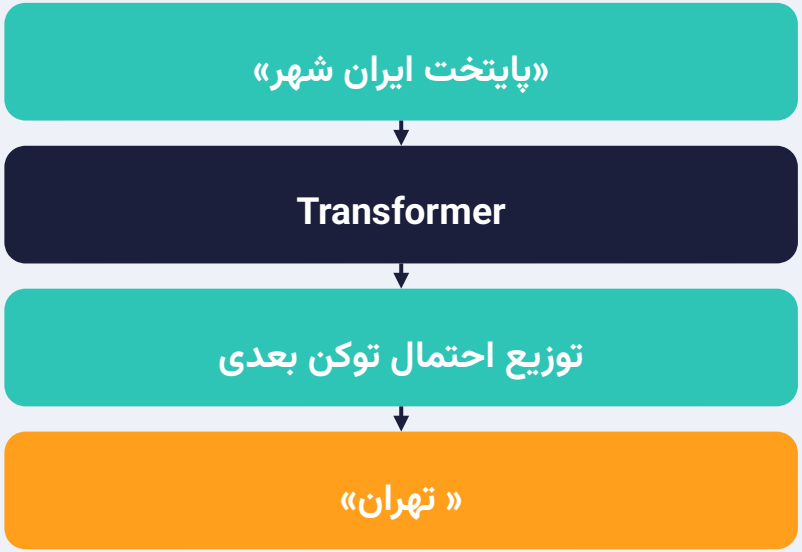
۶ API سازگار با OpenAI

۷ پارامترهای تولید و استریم

۸ سرعت، هزینه و انتخاب مدل

LLM چیست؟

- کار اصلی هر مدل زبانی: **پیش‌بینی توکن بعدی** با دیدن توکن‌های قبلی.
- خروجی مدل یک توزیع احتمال روی همه توکن‌های واژگان است.
- تولید متن یعنی تکرار: پیش‌بینی، انتخاب یک توکن، افزودن به ورودی.
- همان Transformer جلسه ۱۳ دوره یادگیری عمیق، با میلیاردها پارامتر.



تولید خودبازگشتی

$$P(x_t \mid x_1, x_2, \ldots, x_{t-1})$$

- در هر گام فقط یک توکن تولید می‌شود و به انتهای ورودی اضافه می‌شود.
- **رمزگشایی حریصانه (Greedy):** همیشه محتمل‌ترین توکن؛ قطعی ولی تکراری.
- **نمونه‌برداری (Sampling):** انتخاب تصادفی بر اساس احتمال‌ها؛ متنوع‌تر.
- طول پاسخ مستقیماً زمان تولید را تعیین می‌کند.

دما (Temperature)

$$p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$

- **T کوچک‌تر از ۱:** توزیع تیزتر و خروجی قابل پیش‌بینی‌تر.
- **T بزرگ‌تر از ۱:** توزیع پهن‌تر و خروجی متنوع‌تر و پرخطاتر.
- **T = 0:** معادل رمزگشایی حریصانه.
- **top_p:** نمونه‌برداری فقط از توکن‌هایی که مجموع احتمالشان به p برسد.

توکن‌سازی و زبان فارسی

.The weather is very nice today

- بیشتر کلمات یک توکن‌اند
- توکن‌ساز BPE روی متن عمدتاً انگلیسی ساخته شده

امروز هوا خیلی خوب است.

- توکن‌های بیشتر برای همان معنا
- کلمات به چند تکه شکسته می‌شوند
- داده آموزشی فارسی کمتر بوده است

پیامدهای توکن بیشتر

۱ هزینه

سرویس‌ها به ازای توکن هزینه می‌گیرند؛ متن فارسی گران‌تر است.

۲ پنجره متن

سقف ورودی بر حسب توکن است؛ متن فارسی زودتر به سقف می‌رسد.

۳ سرعت

تولید هر توکن زمان می‌برد؛ پاسخ فارسی کندتر تولید می‌شود.

از تکمیل‌کننده متن تا دستیار



- خروجی مرحله اول (**Base Model**) فقط متن را ادامه می‌دهد.
- مدل‌های با پسوند **Instruct** یا **Chat** از هر سه مرحله گذشته‌اند.
- هم‌راستاسازی پاسخ‌ها را مفیدتر، صادق‌تر و ایمن‌تر می‌کند.

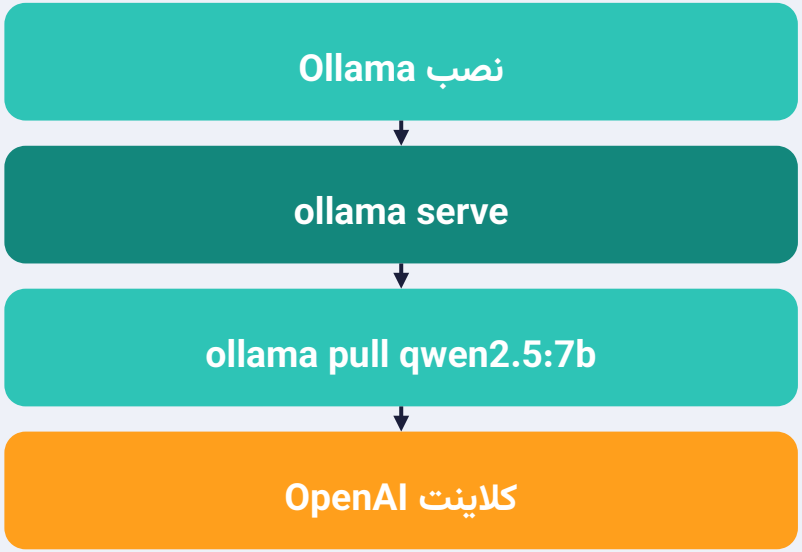
گفتگو هم در نهایت متن است

```
<|im_start|>system
You are a helpful assistant.<|im_end|>
<|im_start|>user
سلام! حالت چطوره؟<|im_end|>
<|im_start|>assistant
```

- پیام‌ها با **Chat Template** به یک متن تبدیل می‌شوند.
- توکن‌های ویژه نقش هر گوینده را مشخص می‌کنند.
- مدل پاسخ را تا توکن پایان `<|im_end|>` تولید می‌کند.
- هر خانواده مدل قالب خودش را دارد؛ قالب غلط کیفیت را خراب می‌کند.

Ollama: سرور مدل‌های متن‌باز

- مدل‌ها را با کوانتیزه‌سازی ۴ بیتی اجرا می‌کند؛ مدل ۷B روی GPU رایگان کولب جا می‌شود.
- یک API سازگار با OpenAI روی پورت ۱۱۴۳۴ ارائه می‌دهد.
- پنجره متن پیش‌فرض کوچک است و ورودی بلندتر **بی‌صدا بریده می‌شود**.
- مدل پیش‌فرض دوره: `qwen2.5:7b`؛ فارسی نسبتاً خوب و پشتیبانی از ابزار.



فراخوانی مدل با کتابخانه openai

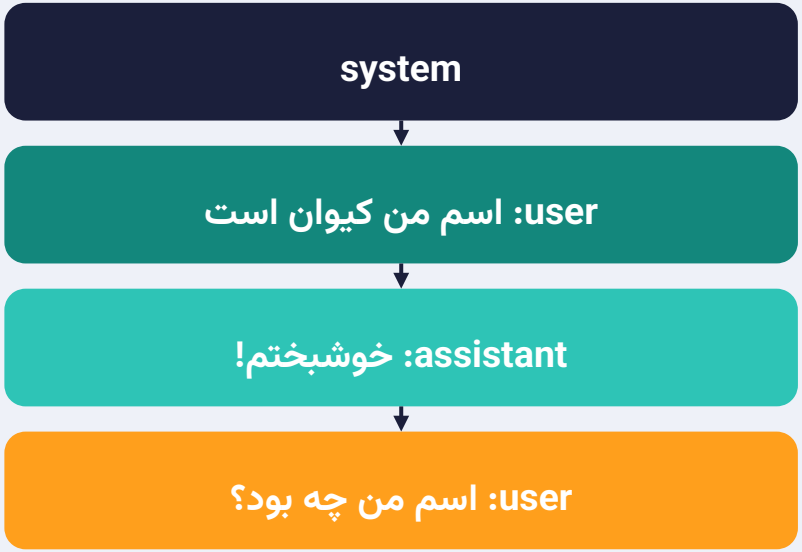
```python
from openai import OpenAI

client = OpenAI(base_url="http://localhost:11434/v1",
                api_key="ollama")

response = client.chat.completions.create(
    model="qwen2.5:7b",
    messages=[
        {"role": "system", "content": "کوتاه پاسخ بده."},
        {"role": "user", "content": "یادگیری ماشین چیست؟"},
    ],
    temperature=0.2,
)
print(response.choices[0].message.content)
print(response.usage)
```

- یک کد برای OpenAI، Ollama و درگاه‌های داخلی.
- فقط `api_key`، `base_url` و نام مدل عوض می‌شود.
- نقش‌ها: **user**، **system** و **assistant**.
- `usage` تعداد توکن‌های ورودی و خروجی را می‌دهد.

مدل حافظه ندارد



- API **بی‌حالت (Stateless)** است و درخواست‌های قبلی را به خاطر نمی‌آورد.
- برای ادامه گفتگو، کل تاریخچه در هر درخواست دوباره ارسال می‌شود.
- گفتگوی طولانی‌تر یعنی ورودی بزرگ‌تر، هزینه بیشتر و پاسخ کندتر.
- مدیریت حافظه گفتگو موضوع جلسه ۱۵ است.

پارامترهای تولید

پارامتر	کاربرد	مقدار رایج
temperature	میزان تصادفی بودن	۰ برای استخراج، ۰٫۷ تا ۱ برای تولید خلاقانه
top_p	نمونه‌برداری از هسته احتمال	۰٫۹ تا ۱
max_tokens	سقف طول پاسخ	بسته به کاربرد
seed	تکرارپذیری نسبی	یک عدد ثابت
stream	ارسال توکن‌ها هم‌زمان با تولید	True در چت‌بات‌ها

همیشه finish_reason را بررسی کنید: مقدار length یعنی پاسخ ناقص است.

مدل محلی یا API؟

معیار	مدل محلی	API تجاری	درگاه داخلی
کیفیت	مدل‌های کوچک ضعیف‌ترند	بهترین کیفیت	همان مدل‌های تجاری
حریم خصوصی	داده خارج نمی‌شود	داده به خارج می‌رود	داده به ارائه‌دهنده می‌رود
هزینه	سخت‌افزار، ثابت	به ازای توکن، ارزی	به ازای توکن، ریالی
دسترسی	همیشه	وابسته به تحریم	وابسته به ارائه‌دهنده

جمع‌بندی

- LLM در هر گام توزیع احتمال توکن بعدی را پیش‌بینی می‌کند.
- دما و top_p تعیین می‌کنند از این توزیع چگونه نمونه بگیریم.
- دستیارها حاصل سه مرحله آموزش‌اند و گفتگو با قالب ویژه به متن تبدیل می‌شود.
- متن فارسی توکن بیشتری مصرف می‌کند: هزینه، سرعت و پنجره متن.
- کد را از سرویس‌دهنده مستقل می‌کند OpenAI سازگار با API.

تمرین

۱ مدل gemma3:4b یا llama3.2:3b را اجرا کنید و کیفیت و سرعت آن را با qwen2.5:7b مقایسه کنید.

۲ نسبت تعداد توکن یک پاراگراف فارسی به ترجمه انگلیسی آن را بسنجید.

۳ تابع ask را طوری تغییر دهید که فقط ۶ پیام آخر ارسال شود و فراموشی مدل را نشان دهید.

۴ اثر seed را با temperature برابر ۰٫۷ روی تکرارپذیری پاسخ‌ها بررسی کنید.