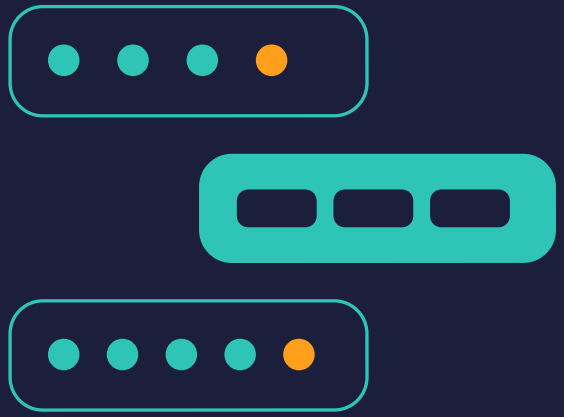
دوره مهندسی LLM و هوش مصنوعی مولد

جلسه ۵

ارزیابی برنامه‌های مبتنی بر LLM



مجموعه آزمون، معیارها، بازه اطمینان و LLM-as-a-Judge

کیوان محمودی

در این جلسه

۱ چرا ارزیابی؟

۲ مجموعه آزمون

۳ معیارهای طبقه‌بندی

۴ مقایسه پرامپت‌ها

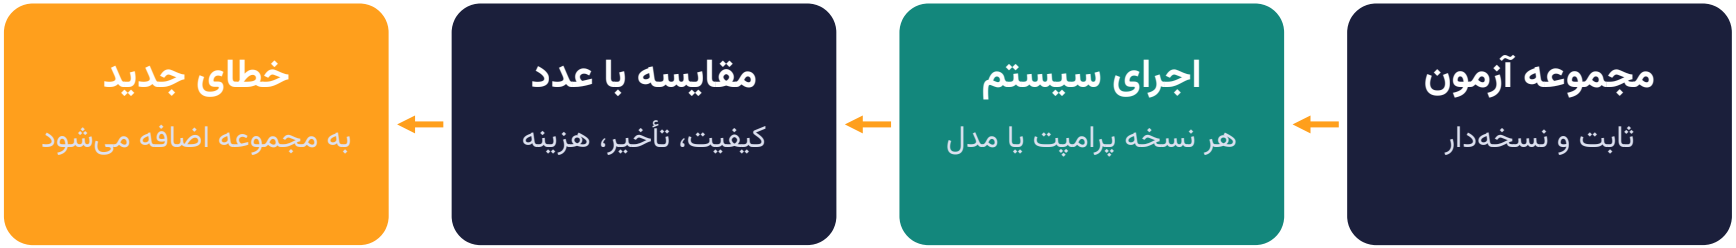
۵ کیفیت، تأخیر و هزینه

۶ بازه اطمینان Bootstrap

۷ LLM-as-a-Judge

۸ سوگیری‌های داور

توسعه ارزیابی‌محور



- ارزیابی برای LLM همان نقشی را دارد که تست در برنامه‌نویسی.
- «Vibe Check» با چند مثال دلبخواه برای تصمیم‌گیری کافی نیست.

روش ارزیابی بر اساس نوع خروجی

روش	نمونه	نوع خروجی
مقایسه مستقیم: دقت، F1	طبقه‌بندی، استخراج قیمت	**برچسب یا مقدار**
اعتبار Schema و دقت هر فیلد	JSON استخراج‌شده	**ساختاریافته**
داور انسانی یا LLM-as-a-Judge	پاسخ پشتیبانی، خلاصه	**متن آزاد**
موفقیت کار، تعداد گام، هزینه	ایجنت	**چندمرحله‌ای**

مجموعه آزمون خوب

۱ واقعی و متنوع

- از داده واقعی
- شامل موارد دشوار و مرزی

۲ پاسخ درست دقیق

- برچسب با دقت تعیین‌شده
- ترجیحاً تأیید دو نفر

۳ ثابت و جدا

- نسخه‌دار
- جدا از مثال‌های Few-shot
- Dev برای کار، Test برای گزارش

Precision، Recall و F1

$$P = \frac{TP}{TP + FP} \qquad R = \frac{TP}{TP + FN} \qquad F_1 = \frac{2PR}{P + R}$$

- **Precision:** از نمونه‌هایی که مدل گفت «منفی»، چند درصد واقعاً منفی بودند؟
- **Recall:** از نظرات منفی واقعی، چند درصد پیدا شد؟
- **Macro-F1:** میانگین F1 همه کلاس‌ها با وزن برابر؛ مناسب کلاس‌های نامتوازن.
- برای فروشگاه، **Recall کلاس منفی** مهم‌ترین عدد است.

مقایسه سه پرامپت

هزینه ورودی	ویژگی	سیستم
کم	دستورالعمل انگلیسی، بدون مثال	**zero-shot EN**
کم تا متوسط	همان دستورالعمل به فارسی	**zero-shot FA**
چند برابر	دستورالعمل انگلیسی با ۴ مثال	**few-shot EN**

انتخاب نهایی همیشه موازنه کیفیت، تأخیر و هزینه است.

بازه اطمینان با Bootstrap

```
def bootstrap_ci(correct, n_boot=1000):
    rng = np.random.default_rng(0)
    samples = rng.choice(correct,
                         size=(n_boot, len(correct)),
                         replace=True).mean(axis=1)
    return np.percentile(samples, [2.5, 97.5])

# accuracy=0.85   95% CI=[0.75, 0.94]
```

- با ۴۸ نمونه، هر نمونه حدود ۲٪ دقت است.
- اختلاف ۴ درصدی ممکن است فقط شانس باشد.
- **مقایسه جفتی:** فقط نمونه‌هایی که دو سیستم سر آن اختلاف دارند.
- برای تصمیم مهم، صدها نمونه لازم است.

LLM-as-a-Judge

```
class Grade(BaseModel):
    reasoning: str
    score: Literal[1, 2, 3, 4, 5]

# 5 = all facts correct and complete
# 4 = correct, minor detail missing
# 3 = partly correct
# 2 = mostly wrong
# 1 = wrong or irrelevant
```

- برای متن آزاد پاسخ درست یکتا وجود ندارد؛ مقایسه کلمه‌به‌کلمه بی‌معناست.
- داور انسانی بهترین ولی گران و کند است.
- کلید داوری: **معیار (Rubric)** روشن و **پاسخ مرجع**.
- از داور بخواهید **اول دلیل، بعد نمره** بدهد.
- داور را هم ارزیابی کنید: توافق با نمره انسانی.

دو روش داوری

نمره مطلق

- نمره ۱ تا ۵ با معیار
- قابل مقایسه در طول زمان
- نیاز به پاسخ مرجع
- کمتر حساس به تفاوت‌های ظریف

مقایسه جفتی

- کدام پاسخ بهتر است؟
- حساس به تفاوت‌های ظریف
- مناسب مقایسه دو نسخه
- در معرض سوگیری جایگاه

سوگیری‌های داور

۱ جایگاه

ترجیح پاسخ اول یا دوم؛ راه‌حل: اجرای دوطرفه و حذف داوری‌های ناسازگار.

۲ طول

ترجیح پاسخ بلندتر، حتی بدون اطلاعات بیشتر.

۳ خودشیفتگی

ترجیح پاسخ مدل‌های هم‌خانواده با داور.

۴ لحن

پاسخ مطمئن و مؤدب حتی اگر غلط باشد نمره بیشتری می‌گیرد.

ابزارهای ارزیابی

کاربرد	ابزار
مقایسه پرامپت و مدل با فایل پیکربندی؛ مناسب CI	**promptfoo**
ارزیابی به سبک pytest با معیارهای آماده	**DeepEval**
معیارهای ویژه RAG (جلسه ۹)	**Ragas**
ثبت اجراها، ارزیابی و پایش عملیاتی	**LangSmith، Langfuse**

مهم‌تر از ابزار: هیچ تغییری بدون اجرای ارزیابی پذیرفته نمی‌شود.

جمع‌بندی

- ارزیابی برای LLM نقش تست را دارد.
- مجموعه آزمون: واقعی، متنوع، نسخه‌دار و جدا از داده ساخت.
- دقت کافی نیست؛ Macro-F1، Recall، Precision و ماتریس درهم‌ریختگی.
- با داده کم، بازه اطمینان را گزارش کنید.
- LLM-as-a-Judge با معیار و پاسخ مرجع؛ مراقب سوگیری‌ها باشید.

تمرین

۱ نسخه Few-shot با دستورالعمل فارسی بسازید و با بازه اطمینان مقایسه کنید.

۲ ده نظر دشوار (طعنه‌آمیز یا دوگانه) به مجموعه آزمون اضافه کنید.

۳ پنج پاسخ را خودتان نمره بدهید و توافق با داور را بسنجید.

۴ سوگیری طول داور را با افزودن یک جمله بی‌اطلاعات بسنجید.