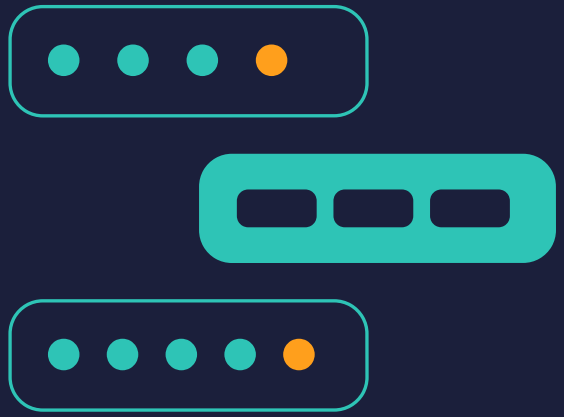
دوره مهندسی LLM و هوش مصنوعی مولد

## جلسه ۶

# امبدینگ و جستجوی معنایی



امبدینگ جمله، شباهت کسینوسی، جستجوی معنایی، FAISS و Chroma

کیوان محمودی

# در این جلسه


۱ امبدینگ جمله

۲ شباهت کسینوسی

۳ مدل E5 چندزبانه

۴ موتور جستجوی معنایی

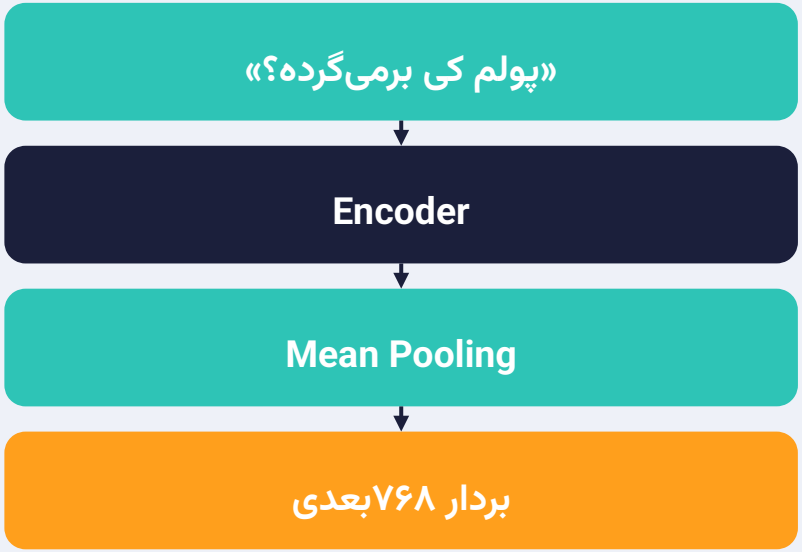
۵ معنایی یا کلیدواژه‌ای؟

۶ FAISS و جستجوی تقریبی

۷ پایگاه داده برداری Chroma

۸ خطاهای رایج

# امبدینگ جمله




- کل متن به یک بردار با طول ثابت (مثلاً ۷۶۸) تبدیل می‌شود.
- متن‌های هم‌معنا بردارهای نزدیک دارند، حتی بدون کلمه مشترک.
- مدل: یک Encoder خانواده BERT با **Mean Pooling**.
- آموزش با **یادگیری متضاد**: پرسش نزدیک پاسخ درست، دور از بقیه.
- پایه جستجوی معنایی و RAG.

# شباهت کسینوسی

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \, \|\mathbf{b}\|}$$

- ۱ یعنی هم‌جهت؛ نزدیک صفر یعنی بی‌ربط.
- با بردارهای **نرمال**، شباهت کسینوسی همان ضرب داخلی است.
- عدد مطلق در مدل‌ها فرق دارد؛ در E5 متن بی‌ربط هم حدود ۰٫۷ است.
- آنچه مهم است **ترتیب** شباهت‌هاست.

# مدل E5 چندزبانه

- بیش از ۹۰ زبان، از جمله فارسی.
- قرارداد: پیشوند `query:` و `passage:`.
- فراموش کردن پیشوند کیفیت را پایین می‌آورد.
- حداکثر ورودی ۵۱۲ توکن.

```python
from sentence_transformers import SentenceTransformer

embedder = SentenceTransformer(
    "intfloat/multilingual-e5-base")

def embed_queries(texts):
    return embedder.encode(
        [f"query: {t}" for t in texts],
        normalize_embeddings=True)

def embed_passages(texts):
    return embedder.encode(
        [f"passage: {t}" for t in texts],
        normalize_embeddings=True)
```

# جستجوی معنایی در چهار خط

```
passage_vectors = embed_passages(texts)

def semantic_search(query, k=3):
    scores = passage_vectors @ embed_queries([query])[0]
    top = np.argsort(-scores)[:k]
    return [(texts[i], scores[i]) for i in top]

semantic_search("پولم کی برمی‌گرده؟")
# -> بازپرداخت: ظرف ۷۲ ساعت کاری ...
```

- بردار همه پاراگراف‌ها یک بار ساخته می‌شود.
- هر پرسش: یک امبدینگ و یک ضرب ماتریسی.
- پرسش محاوره‌ای سند رسمی را پیدا می‌کند.

# معنایی یا کلیدواژه‌ای؟

| معنایی | کلیدواژه‌ای | معیار |
|---|---|---|
| نزدیکی معنا | کلمات مشترک | **مبنا** |
| خوب کار می‌کند | شکست می‌خورد | **مترادف و زبان محاوره** |
| ممکن است اشتباه کند | دقیق | **کد و نام خاص (NK482913)** |
| دارد | ندارد | **نیاز به مدل** |

در جلسه ۹ این دو را با جستجوی ترکیبی (Hybrid Search) ترکیب می‌کنیم.

# FAISS: دقیق یا تقریبی؟

### Flat (دقیق)

- مقایسه با همه بردارها
- دقت کامل
- کند در مقیاس بزرگ
- برای چند ده هزار بردار کافی

### HNSW (تقریبی)

- گرافی از همسایه‌ها
- چند ده برابر سریع‌تر
- دقت کمی پایین‌تر
- برای میلیون‌ها بردار

# پایگاه داده برداری Chroma

```
chroma = chromadb.PersistentClient(path="chroma_db")
col = chroma.get_or_create_collection(
    "novinkala", metadata={"hnsw:space": "cosine"})

col.upsert(ids=ids, documents=texts,
           embeddings=vectors,
           metadatas=[{"source": s} for s in sources])

col.query(query_embeddings=q_vec, n_results=3,
          where={"source": {"$in": ["01_shipping.md",
                                    "02_returns.md"]}})
```

- متن، بردار و **متادیتا** کنار هم.
- ذخیره روی دیسک و به‌روزرسانی.
- **فیلتر متادیتا** جستجو را محدود می‌کند.
- گزینه‌های دیگر: Qdrant، Milvus، pgvector.

# خطاهای رایج

| خطا | پیامد | راه‌حل |
|---|---|---|
| **فراموش کردن پیشوند E5** | افت کیفیت | کپسوله کردن در تابع |
| **مدل متفاوت برای شاخص و پرسش** | نتایج بی‌معنی | ذخیره نام مدل کنار شاخص |
| **متن بلندتر از ۵۱۲ توکن** | بریده شدن بی‌صدا | تقسیم متن (جلسه ۷) |
| **آستانه ثابت شباهت** | حذف نتیجه درست | تنظیم با داده ارزیابی |

# مدل‌های امبدینگ

| ویژگی | مدل |
| --- | --- |
| چندزبانه، رایگان، خوب برای فارسی | **multilingual-e5-base / large** |
| ورودی تا ۸۱۹۲ توکن، کیفیت بالاتر، کندتر | **BAAI/bge-m3** |
| اجرا با Ollama و API سازگار با OpenAI | **nomic-embed-text (Ollama)** |
| سرویس پولی OpenAI، بدون GPU | **text-embedding-3-small** |

# جمع‌بندی

- امبدینگ متن‌های هم‌معنا را نزدیک هم قرار می‌دهد.
- با بردار نرمال، شباهت کسینوسی همان ضرب داخلی است.
- معنایی برای مترادف و محاوره؛ کلیدواژه‌ای برای کد و نام خاص.
- FAISS برای سرعت، Chroma برای متن، متادیتا و ذخیره‌سازی.
- قرارداد مدل را رعایت کنید: پیشوند و حداکثر طول.

# تمرین

۱ اثر حذف پیشوندهای query و passage را روی پنج پرسش بسنجید.

۲ ده پرسش محاوره‌ای بنویسید و جستجوی معنایی و کلیدواژه‌ای را مقایسه کنید.

۳ مدل bge-m3 را جایگزین کنید و کیفیت و سرعت را مقایسه کنید.

۴ متادیتای topic بسازید و فقط در اسناد مالی جستجو کنید.