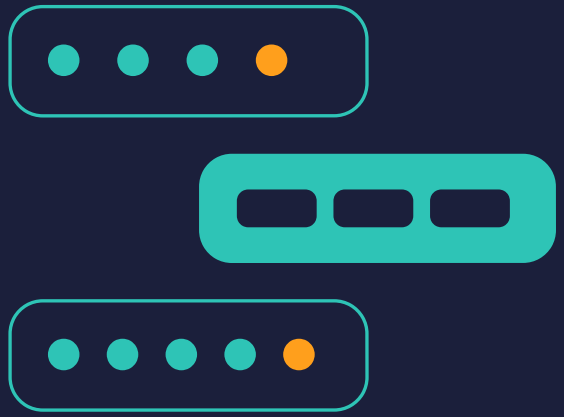
دوره مهندسی LLM و هوش مصنوعی مولد

جلسه ۷

آماده‌سازی اسناد فارسی برای RAG



استخراج متن از Word و PDF، سنجش کیفیت، نرمال‌سازی و تقسیم متن

کیوان محمودی

در این جلسه

۱ خط لوله RAG

۲ خواندن فایل Word

۳ مشکلات PDF فارسی

۴ سنجش کیفیت استخراج

۵ نرمال‌سازی متن فارسی

۶ چرا تقسیم متن؟

۷ سه روش تقسیم

۸ مقایسه با ارزیابی

خط لوله RAG: بخش آماده‌سازی



- پاسخ‌گویی: امبدینگ پرسش، بازیابی تکه‌ها، ساخت پرامپت و تولید پاسخ (جلسه ۸).
- **Garbage in, garbage out:** متن خراب یعنی پاسخ خراب، با هر مدلی.

Word یا PDF؟

Word

- ساختار دارد: سبک عنوان و متن
- ترتیب منطقی متن حفظ شده
- استخراج دقیق با python-docx
- قابل تبدیل به Markdown

PDF

- برای نمایش طراحی شده
- هر حرف یک نقش با مختصات
- ترتیب و جهت باید حدس زده شود
- خطای زیاد برای متن فارسی

خطاهای استخراج PDF فارسی

خروجی استخراج	متن اصلی	مشکل
کردن نهایی هنگام ارسال روش	روش ارسال هنگام نهایی کردن	**ترتیب کلمات (pypdf)**
کاال، اعالم، تالش	کالا، اعلام، تلاش	**حرف ترکیبی «لا»**
.نمایش داده می‌شود	... نمایش داده می‌شود.	**جای نقطه**
جمله در چند خط جدا	یک جمله کامل	**شکستن خط**

PyMuPDF بسیار بهتر از pypdf است، ولی خطای «لا» و جای نقطه را دارد.

سنجش کیفیت با پوشش واژه‌نامه

```
LEXICON = set(hazm.utils.words_list())

def lexicon_coverage(text):
    words = WORD.findall(text)
    return sum(in_lexicon(w) for w in words) / len(words)

# DOCX            ~ مرجع
# pypdf           پایین
# PyMuPDF         متوسط
# PyMuPDF + fixes نزدیک به مرجع
```

- به جای نگاه به چند خط، **اندازه بگیرید**.
- درصد کلمات موجود در واژه‌نامه ۲۰۰ هزارتایی hazm.
- پسوندهای رایج (ها، های، ی) جدا می‌شوند.
- اصلاح «لا» فقط وقتی که کلمه اصلاح‌شده در واژه‌نامه باشد.

نرمال‌سازی متن فارسی

نرمال‌شده	نمونه	مشکل
علی، کتاب	علي، کتاب	**ی و ک عربی**
یک شکل واحد	۱۲ و ١٢ و 12	**ارقام**
می‌روم	می روم، میروم	**نیم‌فاصله**
کتاب	کِتـــاب	**اعراب و کشیده**
سلام، خوبی؟	سلام ،خوبی ؟	**فاصله علائم**

اسناد و پرسش‌ها باید با یک روش یکسان نرمال شوند.

چرا تقسیم متن؟

۱ محدودیت مدل

E5 فقط ۵۱۲ توکن اول را می‌بیند؛ بقیه بی‌صدا بریده می‌شود.

۲ دقت بازیابی

بردار سند بلند میانگین موضوعات زیادی است و به هیچ پرسشی خیلی شبیه نیست.

۳ هزینه و تمرکز

فقط تکه‌های مرتبط وارد پرامپت می‌شوند، نه کل سند.

سه روش تقسیم

۱ اندازه ثابت

- هر n کاراکتر یک تکه
- هم‌پوشانی بین تکه‌ها
- جمله و کلمه را می‌برد

۲ بازگشتی

- اول مرز بخش، بعد پاراگراف، جمله، کلمه
- مرزهای طبیعی حفظ می‌شوند
- RecursiveCharacterTextSplitter

۳ آگاه از ساختار

- تقسیم بر اساس بخش‌ها
- عنوان سند و بخش در هر تکه
- Contextual Chunk Headers

عنوان در هر تکه

- «هزینه آن ۸۵ هزار تومان است» بدون عنوان مبهم است.
- مسیر عنوان‌ها به ابتدای تکه اضافه می‌شود.
- عنوان‌ها در متادیتا هم ذخیره می‌شوند.

```
ارسال و تحویل سفارش > ارسال سریع
ارسال سریع با پیک اختصاصی نوین‌کالا فقط در شهرهای تهران، کرج، اصفهان، شیراز و مشهد انجام می‌شود. ... هزینه ارسال سریع 85 هزار تومان است .
```

مقایسه روش‌ها با ارزیابی

نکته	اندازه	تعداد تکه	روش
مرزها شکسته می‌شوند	یکنواخت	زیاد	**اندازه ثابت ۴۰۰**
مرزهای طبیعی	متغیر	زیاد	**بازگشتی ۴۰۰**
زمینه حفظ می‌شود	متغیر	متوسط	**بخش + عنوان**
Hit Rate بالا ولی پرامپت پرحجم و بریدن ۵۱۲ توکن	بسیار بلند	۱۲	**کل سند**

معیار: Hit Rate@3 روی ۳۰ پرسش با سند منبع مشخص. نتایج را در نوت‌بوک ببینید.

جمع‌بندی

- کیفیت RAG بیش از همه به آماده‌سازی اسناد بستگی دارد.
- PDF آخرین انتخاب است؛ کیفیت استخراج را عددی بسنجید.
- اسناد و پرسش‌ها با یک روش نرمال می‌شوند.
- تقسیم آگاه از ساختار با عنوان در هر تکه زمینه را حفظ می‌کند.
- اندازه و روش تقسیم را با ارزیابی انتخاب کنید.

تمرین

۱ clean_pdf_text را روی خروجی pypdf اجرا کنید؛ چرا اصلاح آن سخت‌تر است؟

۲ اندازه تکه را ۲۰۰، ۴۰۰ و ۸۰۰ کنید و Hit Rate و طول را مقایسه کنید.

۳ روش تقسیم مبتنی بر جمله با sent_tokenize بسازید و مقایسه کنید.

۴ خط لوله را روی یک سند واقعی، مثلاً آیین‌نامه آموزشی، اجرا کنید.