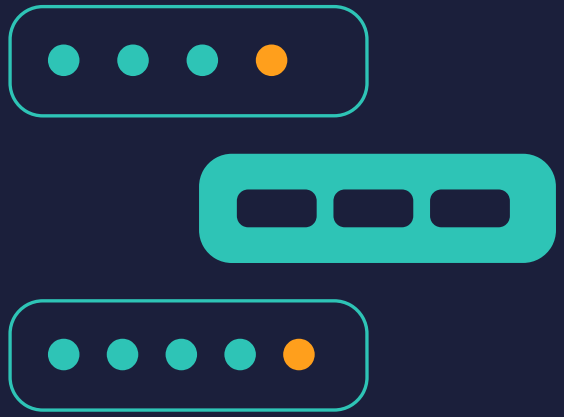
دوره مهندسی LLM و هوش مصنوعی مولد

جلسه ۸

ساخت سیستم RAG



بازیابی، پرامپت مستند به منابع، ارجاع، امتناع و RAG گفتگومحور

کیوان محمودی

در این جلسه

۱ چرا RAG؟

۲ RAG یا فاین‌تیون؟

۳ بازیابی

۴ پرامپت مستند به منابع

۵ ارجاع و امتناع

۶ آزمون‌های دشوار

۷ k و بودجه توکن

۸ RAG گفتگومحور

محدودیت‌های مدل زبانی

۱ دانش اختصاصی

سیاست‌ها، آیین‌نامه‌ها و قراردادهای سازمان شما را ندیده است.

۲ تاریخ توقف

دانش مدل در تاریخ مشخصی متوقف شده است.

۳ توهم

وقتی نمی‌داند، اغلب پاسخ باورپذیر ولی ساختگی می‌دهد.

RAG یا فاین‌تیون؟

فاین‌تیون	RAG	معیار
آموزش دوباره	افزودن سند، فوری	**به‌روزرسانی دانش**
ندارد	دارد	**ارجاع به منبع**
GPU و داده آموزشی	کم	**هزینه شروع**
سبک، قالب و رفتار	دانش و واقعیت‌ها	**مناسب برای**

خط لوله پاسخ‌گویی



- همان مدل امبدینگ و همان نرمال‌ساز برای اسناد و پرسش‌ها.
- تکه‌ها از جلسه ۷: نرمال‌شده با عنوان سند و بخش.

پرامپت مستند به منابع

- سه بخش: دستورالعمل، منابع، پرسش.
- **قاعده امتناع** مهم‌ترین سد در برابر توهم.
- **ارجاع** امکان بررسی پاسخ را می‌دهد.
- منابع در تگ‌های جدا و شماره‌دار.

```
Answer in Persian using ONLY the numbered sources.
- End every factual sentence with its source, e.g. [2].
- If the sources do not contain the answer, reply:
  «متأسفانه در اسناد نوین‌کالا پاسخی پیدا نکردم.»
- Do not guess numbers, prices or dates.

<source id="1">
ارسال و تحویل سفارش > ارسال سریع
... هزینه ارسال سریع 85 هزار تومان است ...
</source>
<source id="2"> ... </source>

Customer question: هزینه ارسال سریع چقدر است؟
```

آزمون‌های دشوار

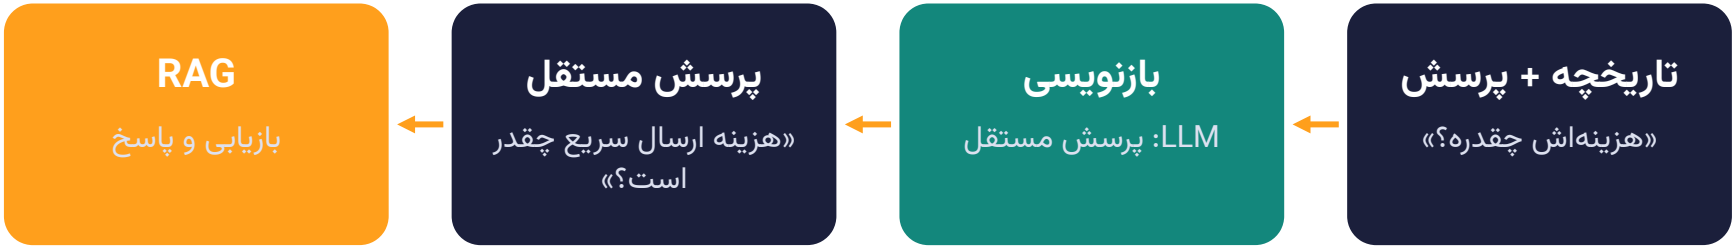
رفتار درست	نمونه	نوع
امتناع	قیمت دلار امروز چنده؟	**خارج از دامنه**
تبریز ارسال سریع ندارد	هزینه ارسال سریع به تبریز؟	**پیش‌فرض غلط**
ترکیب دو سند	یخچال قسطی، پرداخت در محل؟	**ترکیبی**
۲ دقیقه	رمزی که پیامک میشه تا کی اعتبار داره؟	**محاوره‌ای**

مدل‌های کوچک گاهی قاعده امتناع را رعایت نمی‌کنند یا ارجاع غلط می‌دهند؛ جلسه ۹ اندازه‌گیری می‌کنیم.

چند تکه و به چه ترتیب؟

- **k کوچک:** تکه درست در رتبه سوم از دست می‌رود.
- **k بزرگ:** هزینه و تأخیر بیشتر؛ تکه‌های بی‌ربط مدل را گیج می‌کنند.
- **Lost in the Middle:** مدل وسط ورودی طولانی را کمتر می‌بیند.
- مرتبط‌ترین تکه‌ها را **اول** بگذارید.
- بودجه توکن: تکه‌ها را تا سقف مشخص اضافه کنید.

RAG گفتگومحور



- پرسش‌های بعدی به قبلی‌ها وابسته‌اند و به‌تنهایی قابل جستجو نیستند.
- بازنویسی یک فراخوانی اضافه است؛ فقط وقتی تاریخچه هست اجرا شود.

معماری سیستم ما

جایگزین‌ها	انتخاب ما	جزء
بازگشتی، معنایی	بخش + عنوان	**تقسیم متن**
bge-m3، امبدینگ API	multilingual-e5-base	**امبدینگ**
FAISS، Chroma، Qdrant	NumPy	**شاخص**
ترکیبی + Reranker (جلسه ۹)	چگال، top-4	**بازیابی**
هر مدل سازگار با OpenAI	qwen2.5:7b	**تولید**
حافظه خلاصه‌شده (جلسه ۱۵)	بازنویسی پرسش	**گفتگو**

جمع‌بندی

- RAG دانش اختصاصی و به‌روز را بدون آموزش در اختیار مدل می‌گذارد.
- پرامپت RAG: منابع شماره‌دار، ارجاع و قاعده امتناع.
- سیستم را با پرسش‌های دشوار بیازمایید.
- k و بودجه توکن را کنترل کنید؛ مرتبط‌ترین تکه‌ها اول.
- در گفتگو، پرسش را پیش از بازیابی مستقل کنید.

تمرین

۱ قاعده امتناع را حذف کنید و پرسش‌های دشوار را دوباره اجرا کنید.

۲ اگر امتیاز بهترین تکه کم بود، بدون فراخوانی مدل امتناع کنید.

۳ یک بررسی خودکار ارجاع بسازید.

۴ برای اسناد یک حوزه دیگر دستیار RAG بسازید.