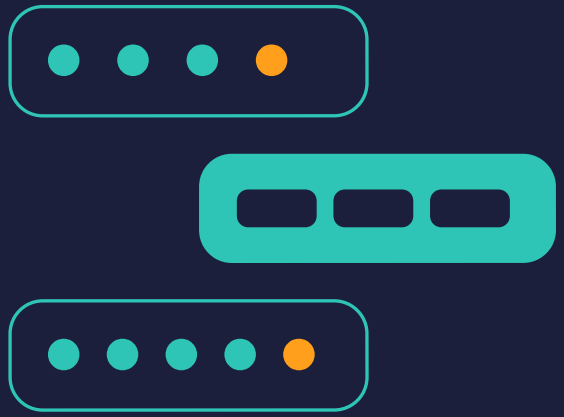
دوره مهندسی LLM و هوش مصنوعی مولد

جلسه ۹

ارزیابی و بهبود RAG



Hit Rate و BM25، MRR، جستجوی ترکیبی، Reranker، وفاداری و تحلیل خطا

کیوان محمودی

در این جلسه

۱ دو جای خراب شدن RAG

۲ معیارهای بازیابی

۳ BM25 برای فارسی

۴ جستجوی ترکیبی RRF

۵ Cross-Encoder Reranker

۶ ارزیابی تولید پاسخ

۷ وفاداری و امتناع

۸ تحلیل خطا

RAG دو جای خراب شدن دارد

خطای بازیابی

- تکه حاوی جواب به مدل نرسیده
- عوض کردن مدل زبانی کمکی نمی‌کند
- راه‌حل: جستجو، تقسیم متن، Reranker

خطای تولید

- تکه درست رسیده
- مدل آن را بد خوانده
- یا چیزی از خودش اضافه کرده
- راه‌حل: مدل یا پرامپت

معیارهای بازیابی

$$\text{MRR} = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{\text{rank}_q}$$

- **Hit Rate@k:** آیا دست‌کم یک تکه مرتبط در k نتیجه اول هست؟
- **MRR:** معکوس رتبه اولین نتیجه مرتبط؛ رتبه ۱ ← ۱، رتبه ۲ ← ۰٫۵.
- MRR به **جایگاه** حساس است؛ تکه‌های بالاتر اثر بیشتری بر پاسخ دارند.

BM25: جستجوی کلیدواژه‌ای حرفه‌ای

```
def tokenize(text):
    return [t for t in word_tokenize(normalize(text))
            if t not in STOPWORDS and len(t) > 1]

bm25 = BM25Okapi([tokenize(c["text"])
                  for c in chunks])
scores = bm25.get_scores(tokenize(query))
```

- **IDF:** کلمه نادر («اقساطی») وزن بیشتری از کلمه رایج («است») دارد.
- **اشباع:** تکرار زیاد یک کلمه امتیاز را بی‌نهایت بالا نمی‌برد.
- **نرمال‌سازی طول:** سند بلند امتیاز ناعادلانه نمی‌گیرد.
- کیفیت برای فارسی به **توکن‌سازی** وابسته است: hazm و حذف Stopwords.

Reciprocal Rank Fusion

$$\mathrm{RRF}(d) = \sum_{r} \frac{1}{c + \mathrm{rank}_r(d)}, \qquad c = 60$$

- امتیاز خام جستجوی معنایی و BM25 قابل مقایسه نیست؛ **رتبه‌ها** را ترکیب می‌کنیم.
- سندی که در هر دو فهرست رتبه خوبی دارد، امتیاز بالایی می‌گیرد.
- ساده، بدون پارامتر یادگرفتنی و در عمل بسیار مؤثر.

Bi-Encoder یا Cross-Encoder؟

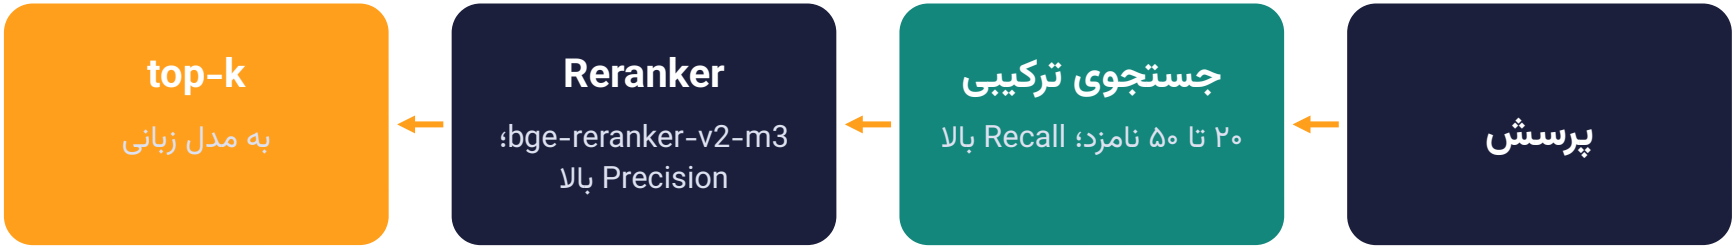
Bi-Encoder (امبدینگ)

- پرسش و تکه جداگانه به بردار تبدیل می‌شوند
- بردار تکه‌ها یک بار ساخته می‌شود
- بسیار سریع
- پرسش و تکه هیچ‌وقت کنار هم دیده نمی‌شوند

Cross-Encoder

- پرسش و تکه با هم وارد مدل می‌شوند
- امتیاز مستقیم مرتبط بودن
- بسیار دقیق‌تر
- کند: یک اجرا برای هر جفت

بازیابی دومرحله‌ای



- بیشترین بهبود Reranker معمولاً در **Hit@1** و **MRR** دیده می‌شود.
- با ۳۰ پرسش، هر پرسش حدود ۳ درصد است؛ اختلاف‌های کوچک را جدی نگیرید.

ابعاد کیفیت پاسخ

روش سنجش	پرسش	بعد
داور با پاسخ مرجع، نمره ۱ تا ۵	پاسخ درست است؟	**درستی**
داور فهرست ادعاهای بی‌پشتوانه را می‌دهد	همه ادعاها در منابع هست؟	**وفاداری**
پرسش‌های خارج از دامنه	وقتی جواب نیست، امتناع می‌کند؟	**امتناع درست**

پاسخ ممکن است درست باشد ولی وفادار نباشد: از دانش قبلی مدل آمده است.

تحلیل خطا

علت	نشانه	راه‌حل
بازیابی	تکه درست در منابع نیست	ترکیبی، Reranker، تقسیم بهتر
نادیده گرفتن منبع	جواب هست، پاسخ غلط	مدل قوی‌تر، پرامپت دقیق‌تر، k کمتر
افزودن از خود	پاسخ وفادار نیست	قاعده سخت‌تر، بررسی ارجاع
امتناع بی‌جا	جواب هست، امتناع کرده	بررسی قاعده امتناع و بازیابی

ابزار آماده: Ragas با معیارهای Faithfulness، Answer Correctness و Context Recall

جمع‌بندی

- بازیابی و تولید را جداگانه ارزیابی کنید.
- Hit Rate@k پیدا شدن و MRR جایگاه را می‌سنجد.
- BM25 مکمل جستجوی معنایی است و RRF آن‌ها را ترکیب می‌کند.
- Reranker ترتیب نامزدها را دقیق‌تر می‌کند.
- درستی، وفاداری و امتناع درست؛ تحلیل خطا مسیر بهبود را نشان می‌دهد.

تمرین

۱ اثر حذف Stopwords و توکن‌ساز hazm را روی BM25 بسنجید.

۲ ترکیب وزن‌دار امتیازهای نرمال‌شده را با RRF مقایسه کنید.

۳ ده پرسش دشوار اضافه کنید و ارزیابی را تکرار کنید.

۴ وفاداری پنج پاسخ را خودتان بررسی و با داور مقایسه کنید.